

PPO强化学习训练分析报告

v17_v50版本训练日志完整分析

训练标识	train_v17_v50.log	环境	Maze Crawler
算法	PPO	总轮次	2000轮
训练时长	16小时11分钟	最终vs随机胜率	90.6%

摘要

本报告对PPO强化学习2000轮完整训练过程进行了系统性分析。通过对性能曲线、Self-Play胜率趋势、Entropy衰减、Loss变化等关键指标的深入研究，评估了训练的收敛状态、效率和异常情况。分析结果显示，本次训练过程稳定，在第1470轮达到69%的峰值胜率后充分收敛。基于分析结果，本报告提出了针对性的改进建议，为后续版本迭代提供了决策依据。

1. 训练概览

1.1 基本参数

项目	数值
总训练轮次	2000轮
训练总时长	58289秒 $\approx$ 16小时11分钟
单轮平均耗时	29.1秒
初始学习率	0.0002
Entropy系数	0.02
Batch大小	100
奖励函数	$\Delta \text{gap} \times 0.5 + \Delta \text{units} \times 0.1$
终端奖励	+5.0 / -1 / 0 (平局)
训练模式	100% Self-Play
评估方式	每10轮混合评估 (100局)
最终vs随机胜率	90.6% (453W-35L-12D)

1.2 训练里程碑

轮次	Best WR	说明
第10轮	23%	首次评估即突破，快速摆脱随机水平
第20轮	39%	快速学习阶段，20轮达到接近40%胜率
第50轮	54%	前50轮快速进步，达到中等智能水平
第360轮	56%	长时间平台期后小幅度提升
第440轮	59%	持续探索带来新的突破
第690轮	64%	中期出现较大提升，策略开始成熟
第1020轮	66%	后期小幅提升
第1230轮	67%	策略进一步精细化
第1390轮	68%	接近收敛时的小幅突破
第1470轮	69%	训练峰值，此后进入完全收敛状态

2. 性能曲线分析




图1: Best Mixed Eval WR性能曲线

2.1 关键发现

- 快速上升期（0-500轮）：胜率从23%快速提升至59%，提升幅度达到36个百分点，占总提升的85.7%
- 缓慢优化期（500-1470轮）：胜率从59%提升至69%，耗时970轮仅提升10个百分点
- 完全收敛期（1470-2000轮）：持续530轮没有任何提升，策略已充分收敛
- 评估稳定性：红色散点显示每10轮评估结果波动逐渐减小，说明策略稳定性增强

2.2 阶段评估

优秀：前期学习速度快，50轮达到54%胜率

良好：中期持续优化，没有出现断崖式下跌

注意：后期收敛速度极慢，边际收益递减严重

3. Self-Play 胜率趋势




图2: Self-Play胜率趋势（含20轮移动平均）

3.1 SP趋势三阶段分析

3.1.1 快速迭代期（0-100轮）

- SP胜率从91%快速下降到23%左右
- 说明策略更新速度极快，新旧版本差异巨大
- 属于正常现象，表明算法在有效探索

3.1.2 持续优化期（100-1000轮）

- SP胜率在20%-40%区间波动
- 策略持续优化但步伐放缓
- 20轮移动平均线呈现平滑下降趋势

3.1.3 收敛稳定期（1000-2000轮）

- SP稳定在25%-40%区间
- 波动范围明显缩小，收敛特征显著
- 移动平均线趋于平缓，策略更新速度大幅降低

3.2 收敛判断

结论：训练已充分收敛。SP波动范围从早期的20%-91%收缩到后期稳定的25%-40%，说明策略探索空间已大幅压缩，趋于稳定。

4. Entropy衰减分析




图3: 策略Entropy衰减曲线

4.1 Entropy关键指标

指标	数值
初始Entropy	0.647
最终Entropy	0.173
总衰减幅度	73.3%
衰减速率	约0.00024 / 轮

4.2 分析结论

- 衰减平稳：Entropy持续稳定下降，没有出现突然崩塌或停滞
- 平衡良好：73%的衰减幅度符合PPO训练的正常探索-利用平衡
- 探索充分：最终Entropy为0.173，仍保留一定探索能力，没有过度贪婪
- 无异常：曲线平滑，没有出现突然的上升或下降，训练过程稳定

5. Loss变化趋势




图4: Policy Loss与Value Loss变化趋势

5.1 Policy Loss分析

- 始终在-0.0004到0.0006之间小幅波动
- 整体接近0，说明策略梯度更新稳定
- 没有出现剧烈震荡或爆炸迹象
- 训练全程保持良好的数值稳定性

5.2 Value Loss分析

- 从初始12.95持续下降到最终1.41左右
- 下降趋势平稳，价值函数拟合度不断提升
- 后期趋于稳定在1.4-2.0区间
- 说明价值网络已充分学习状态价值估计

结论：Loss全程稳定，没有异常。这是一次非常稳定的PPO训练，数值优化过程健康。

6. 训练效率分析




图5: 各阶段训练效率对比 - 边际收益递减分析

6.1 效率数据对比

阶段	达到Best WR	阶段提升	占总提升比例
0-500轮	59%	+59pp	85.5%
500-1000轮	66%	+7pp	10.1%
1000-1500轮	69%	+3pp	4.3%
1500-2000轮	69%	+0pp	0.0%
总计	69%	69pp	100%

6.2 边际收益递减分析

- 1. 前500轮贡献了85.5%的总提升，是训练的黄金期
- 2. 500-1000轮提升明显放缓，但仍有价值
- 3. 1000-1500轮仅提升3个百分点，性价比大幅降低
- 4. 1500-2000轮完全没有提升，属于纯资源消耗

建议：未来训练可在1500轮左右提前停止，或采用动态停止策略（连续200轮无提升即停止），可节省约25%的计算资源。

7. 异常检测

7.1 检测结果综述

总体结论：无重大异常，训练过程健康稳定。

7.2 各项检测明细

检测项目	状态	说明
SP突然暴跌检测	正常	无突然暴跌（如从50%降到10%以下）
Loss爆炸检测	正常	Loss全程稳定，无剧烈震荡
Best WR回退检测	正常	Best WR持续单调上升，无回退
Entropy崩塌检测	正常	Entropy衰减平稳，无突然归零
学习率发散检测	正常	无梯度爆炸或消失迹象

7.3 轻微波动说明

- 第12轮前后SP从50%降到26%：属于正常的策略更迭现象
- 第757轮v50版本切换时SP短暂上升：版本切换正常波动
- 以上波动均在正常范围内，不影响训练质量

8. 最终结论

8.1 收敛性判断

训练已充分收敛

收敛判断依据：

1. Best WR在第1470轮达到69%峰值后，后续530轮零提升
2. SP波动范围从早期20%-91%收缩到后期稳定的25%-40%
3. Entropy已降至0.173的低位，探索空间非常有限
4. Value Loss稳定在1.4-2.0区间，价值函数已充分拟合
5. Policy Loss持续接近0，策略梯度更新饱和

8.2 是否值得继续训练？

不值得继续训练

停止训练理由：

1. 最后530轮完全没有提升，继续训练预期收益为0
2. 计算资源消耗巨大，单轮约29秒，继续训练性价比极低
3. 策略已充分成熟，单纯延长训练难以带来本质性能提升
4. vs随机对手已达90.6%胜率，接近理论天花板

9. 改进建议

基于本次训练分析，对后续版本提出以下改进建议：

9.1 网络结构优化

1. 增加网络容量：尝试更大的隐层神经元数量或增加层数，突破表达能力瓶颈
2. Layer Normalization：加入层归一化稳定训练，允许更大学习率
3. 激活函数优化：尝试GELU、Swish等现代激活函数替代ReLU

9.2 超参数调整

1. 学习率调度：采用余弦退火或线性衰减策略，而非固定学习率
2. Entropy系数：从0.02增加到0.03-0.05，增强后期探索能力
3. Clip范围：动态调整PPO Clip范围（0.15-0.25），平衡稳定性与更新速度

9.3 训练机制创新

1. 对手抽样：实现Prioritized Opponent Sampling，优先对战有挑战性的历史版本
2. 群体进化：实施Population-Based Training，多模型并行进化
3. 专家预训练：引入Expert Demonstration进行监督学习预训练

9.4 奖励塑造改进

1. 权重调整：当前 $\Delta \text{gap} \times 0.5$ 可能过于保守，尝试调至0.7-1.0
2. 探索奖励：加入基于策略多样性的探索奖励，避免过早收敛
3. 动态奖励：实现基于当前胜率的动态奖励调整

9.5 版本迭代策略

1. v50已达瓶颈，建议基于v50做结构性改动而非继续微调
2. 尝试多模型集成策略，融合不同训练阶段的优秀模型
3. 加入知识蒸馏压缩，在保持性能的同时降低推理延迟

10. 预期潜力分析

10.1 当前性能基准

- vs随机对手：90.6%胜率（453W-35L-12D）
- vs v6版本：预估约70%胜率
- Best混合评估：69%胜率

10.2 理论天花板估计

- vs随机对手理论天花板约95%-97%
- 当前已达90.6%，剩余提升空间约4-6个百分点
- 考虑到随机因素影响，实际可挖掘空间约3-5个百分点

10.3 改进预期

改进方向	预期提升幅度
网络结构优化	+1-2pp
超参数精细调优	+0.5-1pp
训练机制创新	+1-3pp
奖励塑造改进	+0.5-1.5pp
多模型集成	+1-2pp
综合优化（叠加效应）	+3-5pp

总结：通过系统性优化，预期可将胜率从69%提升至72-74%左右。但考虑到边际收益递减规律，除非有明确的竞赛目标，否则当前版本已足够优秀，可投入实际应用。