

PPO — v49

■■■■: 2026■

■■■: 2000■

■■■: 15■■53■■ (57222■)

■■■■: 28.6■

[illegible]

Page 10 of 10

■ ■	■ ■
■ ■	PPO (Proximal Policy Optimization)
■ ■ ■ ■ ■	2000
Batch ■ ■	100 ■ / ■
■ ■ ■	0.02
■ ■ ■ ■	100% ■ ■ ■ ■ (Self-play)
■ ■ ■ ■	■ 10 ■ vs ■ ■ ■ ■

Page 10 of 10

- ■■■■: 96% (vs ■■■■)
- ■■■■: 93% ■■
- ■■■■: 226■-186■-88■ (45.2%)

■■■■■■■■■■

[illegible]

■ ■	■ ■ eval_R	■ ■
■ 10 ■	38%	■ ■ ■ ■ ■ ■ ■ ■
■ 40 ■	42%	■ ■ ■ ■ ■ ■

■240■	47%	
■270■	49%	
■340■	50%	■■50%■■
■420■	70%	→ ■■■■■■■■■■
■440■	71%	
■460■	75%	
■740■	84%	■■■■■■■
■1100■	88%	
■1200■	89%	
■1530■	93%	■■90%+
■1550■	95%	■■■■
■1820■	96%	→ ■■■■■

■■■■■: ■■■■■400-450■■■■■■■■■■■■■■■■■■■■

(50%→70-75%)■■■■■■■■■■■5-10■■■■■■■■■■■1820■■■96%■■■■■■

■■■■■■■■■■

1. ■■■■■■ (SP Win Rate)

- ■■■: ■1-100■■■ 15%-35% ■■■■
- ■■■: ■100-800■■■■■■■ 40%-60%
- ■■■: ■800-2000■■■■■ 25%-45%
- ■■■: ■2000■■■ 44%

XX"XXXXXXXXXX"

2. ■■■■■ (Entropy)

■1■: 0.580 (■■■)

■100■: 0.323

■500■: 0.172

■1000■: 0.174

■1500■: 0.179

2000: 0.184

- [illegible]

3. 数据

- Policy Loss (p): 0
- Value Loss (v): 2.8-3.5 1.5-2.0 1.6-2.0
- 数据:

	500	75%
	1000	88%
	1500	95%
	2000	96%

- 0-500: (0%→75%)
- 500-1000: (75%→88%)
- 1000-1500: (88%→95%)
- 1500-2000: (95%→96%)

—

1. Policy Loss
2. SP:
3. eval_R
4. : () ()

96% 2000 93%

- 1500 95% 2000 96% 500 1
-
-

1.

- /
- Transformer
- Layer Norm

2.

- (League Training)
-
- Mini-batch

3.

-
-

4.

- vs Agent
-

5.

-
-

v49 96% PPO 0